


Reading Spatiotemporal Concordances of Floods in Germany

Andreas Wagner

Do not cite without permission. Do get in touch if you want to receive the related publication.

Spatiotemporal Concordance Analysis Pipeline



Today's example:

How are floods talked about in German newspapers?

How can we analyse concordances of the word *Flut* and bring in information about **time** (when are floods talked about) and **place** (where do these floods happen according to the news articles)?

Raw Texts: what is a useful data set?

Service Publikationen Organisation Über uns

IDS LEIBNIZ-INSTITUT FÜR
DEUTSCHE SPRACHE

Service und Informationen des IDS



Onlineangebote

- Korpora
- Wörterbuchportale
- Informationssysteme
- IDS-Bibliografien



Die Bibliothek des IDS

- Bibliothekskatalog
- Externe Kataloge
- Zeitschriftenportal
- E-Books
- Bibliografien und Datenbanken
- Publikationsserver
- Open Access

Raw Texts

- German newspaper articles
- Search word: 'Flut'
- No further restrictions
- Export 10.000 results
 - Select complete texts
 - Limit to a sentence before and after search term
 - Format: csv

COSMAS II [Abmeldung](#) [Recherche](#) [Optionen](#)

Aktuelles Archiv: W1 - Archiv der geschriebenen Sprache **Aktuelles Korpus:** W1-öffentlich - alle öffentlichen Korpora des Archivs W1 (mit Neuakquisitionen) [1]

Aktuelle Suchanfrage: Flut **Referenz:** Deutsches Referenzkorpus DeReKo-2026-I

Treffer: 112.590 **Aktive Treffer:**

Archive Korpus Such. Wortform. Ergebnisse Kook. KWIC Volltext **Export**

Allgemeines

Dateiname: Schriftgröße:

Dateiformat: Orientierung: ☐ Querformat ☒ Hochformat

☐ Ergebnisansicht

☐ KWIC

vorher: Sätze

nachher: Sätze

☒ Volltext

vorher: Sätze

nachher: Sätze

Annotationen: ☒ einblenden ☐ ausblenden

Quellennachweis

☒ exportieren ☐ nachher ☐ fett

Kurzzitierung

☐ Expansionslisten

☐ Korpusansicht

Corpus creation

- Data cleaning
 - Set text format
 - Extract timestamp from ID
- Data preparation
 - Export from excel to csv (recommended separator “;”)

File origin		Delimiter	Data type detection	
65001: Unicode (UTF-8)		Semicolon	Based on first 200 rows	
A ^B _C Column1	A ^B _C Column2	A ^B _C Column...	A ^B _C Column4	A ^B _C Column5
QN	L-Kontext	Treffer	R-Kontext	
A97/APR.00441 St. Galler Tagblatt, 24.04.1997	Zur Heimkehraktion meinte er, dass dies aufgrund der gegenwärtige...	Flut	von Beschwerden über die Ruckschaffung. U...	
A97/APR.00490 St. Galler Tagblatt, 25.04.1997	1100 Postkarten nach Syrien Die Delegiertenversammlung von Al Schweiz in Lugano soll nun, auf In...	Flut	von nahezu 1100 Aufrufen mittels Postkarte an ...	
A97/APR.00917 St. Galler Tagblatt, 26.04.1997	Il postino. Der Postmeister ist überfordert von der	Flut	von Briefen, die schon vor der Ankunft des Dipl...	
A97/APR.01036 St. Galler Tagblatt, 29.04.1997	Die Börse wurde mehrheitlich vom Profihandel dominiert. Die	Flut	an US-Wirtschaftsdaten im Laufe dieser Woche...	
A97/MAI.02334 St. Galler Tagblatt, 07.05.1997	Haben auch ältere Texte eine Chance, oder beginnt unsere ganze N...	Flut	der Netzinforma-tion noch Zeit zur Erinnerung?...	
A97/MAI.03082 St. Galler Tagblatt, 12.05.1997	Aufführung der Kinderkantate Am Mittwoch, 28. Mai, findet zudem im Kirchengemeindehaus eine Auff...	Flut	statt, die von den diesjährigen Grundschüler... Instrumentalunterricht	
A97/MAI.03891 St. Galler Tagblatt, 16.05.1997	Keine leichte Aufgabe. Das Personal des Romans musste ständig aus...	Flut	von Figuren. Die einzige Kraft, die den Roman v...	
A97/MAI.04123 St. Galler Tagblatt, 17.05.1997	Kiarostamis bisherige Filme versprechen nicht nur poetisches Kino, s...	Flut	an Bildern, in denen das Blut massakrierter Me...	
A97/MAI.04214 St. Galler Tagblatt, 20.05.1997	Die Entrüstung der Kritiker ob der	Flut	verschiedener Verfahren nach Intelligenz- und ...	
Ein hoher IQ ist nicht alles Testpsychologen und Therapeuten unterscheiden die				
12	A97/MAI.05521 26.05.1997	unter niederländischer Ratspräsidentschaft stand, musste	hart, knallhart sogar.	
13	A97/MAI.05521 26.05.1997	Zum musikalischen Ausklang des Schuljahres finden verschiedene Konzerte statt. Die nächsten Veranstaltungen	Flut	- Kinderkantate, Grundkurs-Aufführung im evangelischen Kirchengemeindehaus Freitag, 6. Juni, 19 Uhr, Klavierklasse Mancini und Violinklasse Fröhlich (Egelmoos).
14	A97/MAI.05521 26.05.1997	Die Musikgesellschaft Sulgen enttäuschte nicht. Bildete schon das ungewöhnlich originelle und im vornherein gwundrig	Flut	von Höhepunkten, denen die Besucher im Verlauf der gut zwei Stunden begegneten. «Vergessen Sie die Welt ausserhalb des Auholzsaales, vergessen Sie für einmal das Transitabkommen der EU
15	A97/MAI.06471 30.05.1997	* robert schwarz Gegen 23 Kinder und 14 Erwachsene sangen und erzählten die	Flut	von Günther Kretschmar. Mit am Eingang an zuschauende Kinder verteilten grossen Puzzleteile begann das Theater.
16	A97/MAI.06721 31.05.1997	Vertrauen in Lehrkräfte Im Jahresbericht weist Präsident Heinz Naef hin auf die	Flut	von Vernehmlassungen, die innerhalb des letzten Jahres zu diskutieren waren. Die Begeisterung darüber halte sich - so höre er da und dort - in Grenzen.
17	A97/JUN.07451 05.06.1997	So nah wie der Mond kommt uns kein anderer Himmelskörper.	Flut,	sondern auch die Menschen bekommen seine Macht zu spüren - Chronobiologen untersuchen, wie.5 «Wissen»
18	A97/JUN.07521 05.06.1997	Die Chronobiologie, welche sich den rhythmischen Abläufen in der Natur widmet, hat auch den Mond seit langem als einen	Flut	bekommt seine Macht zu spüren. * Rolf App
19	A97/JUN.09831 17.06.1997	Mit einem wundervoll leichtfüssigen «Air de Trompette», von den Bläsern auf der Burgzinne gespielt, wurde das festliche	Flut	In diesem Werk flocht der Komponist verschiedene Tanzformen ein mit Elementen französischer Provenienz.
20	A97/JUN.11271 25.06.1997	Das Angebot wechselt so schnell, dass selbst die Verkäuferinnen nicht immer wissen, was gerade eingetroffen	Flut	an neuen Kleidern nur, weil die Textilkette sämtliche Kollektionen in Billiglohnländern produzieren lässt. Dass dabei «fashion before

NLP and NER



01_Preparation > prepare_and_annotate.py > ...

```
1 import pandas as pd
2 import spacy
3
4
5
6
7
8
9
10
11
12
13
14
15
16
17
18
19
20
21
22
23
24
25
26
27
28
29
30
31
32
33
34
35
36
37 def main():
38     df = read_csv("../00_Data/flood_de/flood_dereko.csv")
39     sentences = concatenatesentences(df)
40     nlp = spacy.load("en_core_web_sm")
41     nlp_item(nlp, sentences)
42     content = create_vrt_file(sentences)
43     with open("../00_Data/flood_de/cwb_corpus.vrt", 'w') as f:
44         f.write(content)
45     print("COMPLETE")
46
47
48 if __name__ == "__main__":
49     main()
```

NLP and NER

<text ...>

<metadata tag...>

<s ...>

word	lemma	POS	entity	
word	lemma	POS	entity	
word	lemma	POS	entity	
...	...		...	...

</s>

<s ...>

...	...		...	...
-----	-----	--	-----	-----

</s>

</metadata tag>

</text>

<text ...>

...

```

<text id=A97/APR.00441 St. Galler Tagblatt, 24.04.1997_0>
<timestamp year="1997" month="04" day=" 24">
<s id=1>
Zur zur ADP None
Heimkehraktion heimkehraktion NOUN None
meinte meinte VERB None
er er PRON None
, , PUNCT None
dass dass ADP None
dies dy NOUN None
aufgrund aufgrund ADP None
der der DET None
gegenwärtigen gegenwärtigen ADJ None
Lage lage NOUN None
zu zu ADP None
realisieren realisieren VERB None
sei sei VERB None
. . PUNCT None
</s>
<s id=2>
Festzustellen festzustellen NOUN None
sei sei VERB None
eine eine DET None
Flut flut NOUN None
von von ADP None
Beschwerden Beschwerden NOUN None
über über ADP None
die die DET None
Rückschaffung rückschaffung NOUN None
. . PUNCT None
</s>
  
```

Conversion

```
#!/bin/bash

set -euo pipefail

# --- Configuration ---
CORPUS_NAME="flood_de"
BASE_PATH="../../Data/${CORPUS_NAME}"

data="${BASE_PATH}/cwb/data"          # data dir
regfile="flood_de"                    # name of the file to be created in registry/ -- lowercase corpus name
name="FLOOD_DE"                       # corpus name in all caps
registry="${BASE_PATH}/cwb/registry"  # registry dir
infile="${BASE_PATH}/cwb_corpus.vrt"  # input file

# --- Remove existing CWB data/registry folders (clean rebuild) ---
echo "Removing existing data and registry folders (if present)..."
rm -rf "$data"
rm -rf "$registry"

# --- Create CWB folder structure ---
mkdir -p "$data"
mkdir -p "$registry"

export CORPUS_REGISTRY="$registry"

echo "cwb-encode"

cwb-encode -d $data -f $infile -R "$registry/$regfile" -xsB -c utf8 -P lemma -P POS -P entity -S text -S s:0+id -S timestamp:0+day+month+year \

# all token-level attributes (POS, lemma, semantic tag...) need to be listed here as -P attribute_name,
# all structural attributes listed with -S attribute_name.
# if your s attributes are part of a larger element like <text>, use the format exemplified by the text attribute here.

# echo "parallel run of cwb-make"
# parallel -j 8 cwb-make -M 4096 -V "$name" ::: word pos


echo "cwb-makeall on remaining attributes"

cwb-makeall -M 4096 -V "$name"
```

Extraction: Recap concordance tools

Concordance View

N	Concordance	Set	Tag	nt.	#	ent.
1	is the technique of linking up the donor's spleen accomplished? 1A thin plastic tube				0	0
2	and its active functioning drops. The donor's spleen braces up the organism, ingesting				22	12
3	other animals. In addition, it is akin to human spleen, having tissues					
4	a view to fortify the organism's protective shield appeared to be futile. Pumped through the live tissue, the bk as if it were driven through the organism's own spleen. The effect was new method was suggested by Professor Anatoly Tsylin, head of depart Institute of Transplantology and Artificial Organs. Pig spleen reacts m					
5	of Transplantology and Artificial Organs. Pig spleen reacts most acti					
6	thin plastic tube connects the artery of the pig's spleen kept in a therm					
7	to be futile. Then surgeons tried to use the spleen as a natural filte					
8	decontaminated by pumping it through the spleen of a pig. As is					



The screenshot shows the AntConc software interface. The main window displays a list of 15 text files (J01.txt to J15.txt) with their respective line numbers and the word 'process' highlighted in each. The 'Target Corpus' is named '2006.AmE06' and contains 80 files with 189608 tokens. The 'Reference Corpus' is empty. The 'Search Query' is 'process' and the 'Context Size' is 10 tokens. The 'Results Set' is 'All hits'. The 'Sort Options' are 'Sort to right', 'Sort 1 1R', 'Sort 2 2R', 'Sort 3 3R', 'Order by freq', 'Fold KPF groups', and 'Group KPF singletons'. The progress bar is at 100%.

https://lexically.net/downloads/version9/HTML/concordance_view.html

<https://www.laurenceanthony.net/software/antconc/>

Extraction: Flexiconc

Line ID	Left Context	Node	Right Context
25	Peter Bauer / New York Über 1000 Tote nach der	Flut	in Somalia Die Hochwasserkatastrophe i m Süden Somalias hat bereits



	cpos	offset	word	lemma	POS	entity	line_id	id_in_line
id								
530	3104	-5	Über	über	ADV	None	25	5
531	3105	-4	1000	1000	NUM	CARDINAL	25	6
532	3106	-3	Tote	tote	NOUN	None	25	7
533	3107	-2	nach	nach	ADP	None	25	8
534	3108	-1	der	der	DET	None	25	9
535	3109	0	Flut	Flut	PROPN	None	25	10
536	3110	1	in	in	ADP	None	25	11
537	3111	2	Somalia	Somalia	PROPN	GPE	25	12

```
node_03.view()['token_spans']
```

```
[{'line_id': 12,
 'start_id_in_line': 13,
 'end_id_in_line': 13,
 'category': 'A',
 'weight': 1,
 'tokens_attribute': 'entity',
 'values': ['GPE']},
 {'line_id': 25,
 'start_id_in_line': 12,
 'end_id_in_line': 12,
 'category': 'A',
 'weight': 1,
 'tokens_attribute': 'entity',
 'values': ['GPE']},
 {'line_id': 39,
 'start_id_in_line': 5,
 'end_id_in_line': 5,
 'category': 'A',
 'weight': 1,
 'tokens_attribute': 'entity',
 'values': ['GPE']},
 {'line_id': 52,
 'start_id_in_line': 6,
 'end_id_in_line': 6,
 'category': 'A',
 'weight': 1,
 'tokens_attribute': 'entity',
 'values': ['GPE']}]
```

Extraction

Root

- 6.410 hits

Arrangement

- KWIC Ranker: Rank by LOC/GPE within -5 to 5 tokens from KWIC

Subset

- Select by ranked columns ≥ 1 | 824 hits

Extraction

Line ID	Left Context	Node	Right Context
25	Peter Bauer / New York Über 1000 Tote nach der	Flut	in Somalia Die Hochwasserkatastrophe in m Süden Somalias hat bereits

```

item = n3.view()['token_spans'][indexer]
# get the line from the concordance.tokens df by selecting the line_id and the start_id_in_line
line_id = item['line_id']

```

	cpos	offset	word	lemma	POS	entity	line_id	id_in_line
id								
530	3104	-5	Über	über	ADV	None	25	5
531	3105	-4	1000	1000	NUM	CARDINAL	25	6
532	3106	-3	Tote	tote	NOUN	None	25	7
533	3107	-2	nach	nach	ADP	None	25	8
534	3108	-1	der	der	DET	None	25	9
535	3109	0	Flut	Flut	PROPN	None	25	10
536	3110	1	in	in	ADP	None	25	11
537	3111	2	Somalia	Somalia	PROPN	GPE	25	12

Georeferencing and Clustering

“Geocoding is the process of converting an address, place name, or point of interest into geographic coordinates (latitude and longitude).”

(Stadia maps, 2026)


- Geocoding looks up a place name in a Gazetteer (a database of geonames)
- Place names are ambiguous  resolution needed
 - Probability based
 - Context based
 - ...

```
def parse_coordinates(location_name):
    geolocator = Nominatim(user_agent=USER_AGENT)
    location = geolocator.geocode(location_name)
    if location:
        return (location.latitude, location.longitude)
    else:
        return (None, None)
```

	cpos	offset	word	POS	lemma	entity	line_id	id_in_line	location_name	coordinates
0	1382	3	Polen	PROPN	Polen	GPE	12	13	Polen	(52.215933, 19.134422)
1	2196	-8	Graz	PROPN	Graz	GPE	21	2	Graz Bruchstücke	(None, None)
2	3102	8	New	PROPN	New	GPE	24	18	New York	(40.7127281, -74.0060152)
3	3102	-7	New	PROPN	New	GPE	25	3	New York	(40.7127281, -74.0060152)
4	3111	2	Somalia	PROPN	Somalia	GPE	25	12	Somalia	(8.3676771, 49.083416)

Geocoding and Clustering

- Cluster to abstract the pointwise information to areas/regions talked about
- Administrative regions and geographical WITHIN relation



	cpos	offset	word	POS	lemma	entity	line_id	id_in_line	location_name	coordinates	geometry	country	region	country_code
0	1382	3	Polen	PROPN	Polen	GPE	12	13	Polen	(52.215933, 19.134422)	POINT (19.134422 52.215933)	Poland	Europe	616

Metadata: data about data context in which the language is used

Example: spoken data

Metadata categories:

- Age
- Gender
- Accent / dialect
- Occupation



Metadata: important questions

- What metadata is useful for the research question?
 - Time (published at)
 - Location (talked about)
- Where to find this metadata?
 - Corpus information (on download)
 - Additional metadata whilst analysis
- How to store this data?
 - Keep references to original data
 - Usually Unique IDs are used

Today's example:

How are floods talked about in German newspapers?

How can we analyse concordances of the word *Flut* and bring in information about **time** (when are floods talked about) and **place** (where do these floods happen according to the news articles)?

Metadata creation

What?

Where?

How?

	cpos	offset	word	POS	lemma	entity	line_id	id_in_line	location_name	coordinates	geometry	country	region	country_code
0	1382	3	Polen	PROPN	Polen	GPE	12	13	Polen	(52.215933, 19.134422)	POINT (19.134422 52.215933)	Poland	Europe	616

Metadata creation

- By using the line-id as parameter, we can now add the retrieved information to the metadata table of our concordance line

```
# for each line of the metadata dataframe, get the region from the geospatial_df by comparing the line_id and add the first region found as a new column to the metadata_copy dataframe
concordance.metadata['region'] = concordance.metadata['line_id'].apply(lambda x: geospatial_df[geospatial_df['line_id'] == x]['region'].values[0] if x in geospatial_df['line_id'].values else 'Unknown')
```

	cpos	offset	word	POS	lemma	entity	line_id	id_in_line	location_name	coordinates	geometry	country	region	country_code
0	1382	3	Polen	PROPN	Polen	GPE	12	13	Polen	(52.215933, 19.134422)	POINT (19.134422 52.215933)	Poland	Europe	616

	context	contextend	text	s	s_id	timestamp	timestamp_day	timestamp_month	timestamp_year	displayString	displayStringTripartite	line_id
id												
0	89	109	2	5	1	2	26	04	1997	. Il postino. Der Postmeister ist überfordert ...	{'left': '. Il postino. Der Postmeister ist üb...	0
1	191	211	4	11	1	4	07	05	1997	mit der Geburt des Internet? Bleibt uns in der...	{'left': 'mit der Geburt des Internet? Bleibt ...	1

Filtering

Filtering

```
node_04 = concordance.root.add_arrangement_node(  
    grouping=(  
        'Partition by Metadata Attribute', {  
            'metadata_attribute': 'timestamp_year',  
            'sort_by_partition_size': True  
        }  
    ),  
    ordering=[(  
        'Sort by Token-Level Attribute', {  
            'tokens_attribute': 'lemma',  
            'sorting_scope': 'token',  
            'offset': -1,  
            'case_sensitive': False,  
            'reverse': False,  
            'backwards': False,  
            'locale_str': 'en'  
        }  
    ), (  
        'KWIC Grouper Ranker', {  
            'search_terms': ['LOC', 'GPE'],  
            'tokens_attribute': 'entity',  
            'mode': 'literal',  
            'case_sensitive': False,  
            'include_node': False,  
            'window_start': -10,  
            'window_end': 10,  
            'count_types': True  
        }  
    )  
],  
    labelling=None,  
    max_depth=0)
```

1. Group by year
2. Order by lemma
3. Group by entity (highlights entities as well)
4. Select by metadata

```
# select just the concordance lines with metadata country = Germany  
node_05 = node_04.add_subset_node([(  
    'Select by Metadata Attribute',  
    {  
        'metadata_attribute': 'country',  
        'value': "Germany",  
        'operator': '==',  
        'regex': False,  
        'case_sensitive': False,  
        'negative': False  
    }  
)])
```

Qualitative Interpretation

Line ID	R1	Left Context	Node	Right Context
		► 2014 (22 lines)		
		► 2013 (82 lines)		
		► 2012 (30 lines)		
		► 2011 (26 lines)		
		► 2010 (46 lines)		

Line ID	R1	Left Context	Node	Right Context
		► 2014 (22 lines)		
		► 2013 (82 lines)		
		► 2012 (30 lines)		
2515	1	Und was passiert in der Speicherstadt eigentlich bei Ebbe,	Flut	und Sturmflut? Bei der Speicherstadt - Entdeckertour für Kinder
4926	1	Tierfreunde mit Haus und Garten", sagt Ternes,	Flut	von Anfragen Auch in Worms hat sich die Lage entspannt
4928	1	paar nette Interessenten ausgesucht", so eine Sprecherin,	Flut	von Anfragen Auch in Worms hat sich die Lage entspannt
1465	1	an die Tschernobyl - Kinder und 2002/2003 an Opfer der	Flut	in Dresden. Vielfältig und sogar international engagiert ist die
2191	1	. www.haz.de 50 Jahre danach: Was Hamburg aus der	Flut	gelernt hat / der 7. tag Seine Nachfolge bei
2198	1	der sich außerhalb Bayerns nicht Zwei Millionen Inderflüchten vor der	Flut	Guwahati (afp). Harsche Kritik an Twitter New
2524	1	. Erst wurde getrauert, dann rangeklotzt. Nach der	Flut	von 1962 investierte Hamburg immer wieder Millionen in seine Deiche
2526	1	81) mit den Schallplatten, die sie nach der	Flut	i m Schutt ihres Hauses fanden. Nirgends wütete die
2554	1	vor der Küste Helgolands in Warteposition gehen und mit der	Flut	heute Nachmittag Wilhelmshaven erreichen."Falls die Task Force
4905	1	, i m kalten Deutschland zu bleiben. Nach der	Flut	Auf bis zu 5,80 Meter ist der Pegel des Neckars

Further steps/information

- The georeferenced information can also be used as token-level annotation
- The clustered data can be displayed on a map as well, showing quantity of linguistic features describing an area
- The metadata table can be used to further add metadata information extracted from the concordance itself
- Location nowadays is a complicated topic

Further steps/information

- Linked Open Data

 Wikidata Query Service

Beispiele
 Hilfe
 Weitere Werkzeuge
 Abfragegenerator

Deutsch

```

1 SELECT ?item ?itemLabel ?itemDescription ?coord ?countryLabel WHERE {
2   SERVICE wikibase:mwapi {
3     bd:serviceParam wikibase:endpoint "www.wikidata.org" ;
4     wikibase:api "EntitySearch" ;
5     mwapi:search "Nürnberg" ;
6     mwapi:language "de" .
7     ?item wikibase:apiOutputItem mwapi:item .
8   }
9   ?item wdt:P625 ?coord .           # nur Dinge mit Koordinaten
10  OPTIONAL { ?item wdt:P17 ?country . }
11  SERVICE wikibase:label { bd:serviceParam wikibase:language "de,en". }
12 }

```

Table

29 Ergebnisse in 689 ms

</> Code

Herunterladen

Link

item	itemLabel	itemDescription	coord	countryLabel
wd:Q2090	Nürnberg	Großstadt in Bayern, Deutschland	Point(11.0775 49.453888888)	Deutschland

Further steps/information

```
SELECT ?item ?itemLabel ?itemDescription ?coord ?countryLabel WHERE {  
  SERVICE wikibase:mwapi {  
    bd:serviceParam wikibase:endpoint "www.wikidata.org" ;  
    wikibase:api "EntitySearch" ;  
    mwapi:search "Nürnberg" ;  
    mwapi:language "de" .  
    ?item wikibase:apiOutputItem mwapi:item .  
  }  
  ?item wdt:P625 ?coord .          # nur Dinge mit Koordinaten  
  OPTIONAL { ?item wdt:P17 ?country . }  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "de,en". }  
}
```